

第一次作业

第一题：根据 Tom Mitchell 在《[Machine learning](#)》一书中的定义：

“一个计算机程序如果随着经验 **E** 的增加，其在任务 **T** 上的性能（以性能度量 **P** 衡量）有所提高，那么就称该程序从经验中学习，此时其被认为是一个机器学习模型。”

“A computer program is said to learn from experience **E** with respect to some task **T** and some performance measure **P**, if its performance on **T**, as measured by **P**, improves with experience **E**.”


请你根据上述定义，解释以下模型中，哪些可以被认为是机器学习模型，并说明你的理由。

- a) 随机猜测 (Random Guess): 无论输入什么数据，都随机地给出一个预测结果。
- b) 判决条例 (Judgment Rule): 由人类专家设定的一套固定规则。
- c) 决策树 (Decision Tree Generated Rules): 通过对训练数据进行特征选择和节点划分来自动生成规则的分类器。
- d) K-近邻 (KNN) 分类器: 根据待分类点与数据点集中 **K** 个最近邻的标签进行投票。

第二题：如下图所示，考虑一个在二维平面上的 K-近邻（KNN）分类，图中红色点代表一类，蓝色点代表另一类，待分类点是坐标原点 $(0, 0)$ 。

（1）请解释为什么在曼哈顿距离（ l_1 范数）和欧几里得距离（ l_2 范数）这两种度量下，坐标原点在 $K=5$ 的 KNN 分类结果不同。

（2）请设计一个对称正定矩阵 $\mathbf{W}$ ，使得在对应的加权欧几里得距离 $D_{\mathbf{W}}(x_1, x_2)^2 = (x_1 - x_2)^T \mathbf{W} (x_1 - x_2)$ 下，坐标原点的 $K=5$ 分类结果与曼哈顿距离下相同，请写出你设计的 $\mathbf{W}$ 矩阵形式，并解释设计原理。



第三题：SVM: $y = \mathbf{w}^T \mathbf{x} + b$

- (1) 当训练数据线性可分时，通过推导解释为什么最小化 $\|\mathbf{w}\|^2$ 能最大化数据点到决策超平面的最小几何间隔 (margin)？
- (2) 训练完成后，满足什么条件的样本需要保留？

第四题：SVM 对偶形式

(1) 写出由原问题 (Primal formulation)

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2, \text{ s. t. } y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1$$

推导得出对偶问题 (Dual formulation)

$$\max_{\lambda} \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle, \text{ s. t. } \sum_{i=1}^n \lambda_i y^{(i)} = 0 \text{ and } \lambda_i \geq 0$$

的具体过程 (基于 KKT 条件)

(2) 解释 Dual formulation 如何引入非线性变换?

第五题：决策树（Decision Tree）


- （1）针对下面表中数据，用 ID3 算法构造一棵决策树，对是否打球进行决策。
- （2）给出一个输入特征：天气晴朗、温度适中、湿度正常、风力弱，通过决策树做出决定是否打球。

标号	天气	气温	湿度	风力	是否打球
1	晴朗	热	高	弱	否
2	晴朗	热	高	强	否
3	阴天	热	高	弱	是
4	有雨	适中	高	弱	是
5	有雨	冷	正常	弱	是
6	有雨	冷	正常	强	否
7	阴天	冷	正常	强	是
8	晴朗	适中	高	弱	否
9	晴朗	冷	正常	弱	是
10	有雨	适中	正常	弱	是
11	晴朗	适中	正常	强	是
12	阴天	适中	高	强	是
13	阴天	热	正常	弱	是
14	有雨	适中	高	强	否


第六题：

区分下列四个决策边界（decision boundary）分别可能来自于哪个分类器？并简要解释原因。


候选项：KNN, SVM（线性）, MLP, Decision Tree。




(1)



(2)



(3)



(4)

第七题：

推导逻辑回归（Logistic Regression）模型目标函数 $L(\mathbf{w})$ 关于参数 $\mathbf{w}$ 的 Hessian 矩阵 $\mathbf{H}$ 。

提示： 逻辑回归的目标函数为：

$$L(\mathbf{w}) = - \sum_{i=1}^n [y_i \log P_i + (1 - y_i) \log(1 - P_i)]$$

$$\text{其中 } P_i = P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\sum_{j=0}^d w_j x_j)}}$$

Hessian 矩阵 $\mathbf{H}$ 是目标函数关于参数 $\mathbf{w}$ 的二阶导数矩阵，其第 (k, l) 个元素为 $\mathbf{H}_{kl} = \frac{\partial^2 L(\mathbf{w})}{\partial w_k \partial w_l}$

第八题：下图是 Lasso 回归的等高线图，Lasso 回归的优化问题定义如下：

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 \quad \text{s.t.} \quad \|\boldsymbol{\beta}\|_1 \leq r$$

请在此图上明确标示一个 l_1 范数约束区域，使得在该区域内，模型的最优解 $\hat{\boldsymbol{\beta}}$ 不会导致任何特征的系数归零，并解释原因。

