

机器学习第一次作业

≡ 姓名	周瑞奇 2025210719 电子工程系
------	----------------------

一、机器学习定义

(a) (b) 不是, (c) (d) 是。随机猜测和预定规则的方法都无法从数据中学习解决问题的“经验”, 它们的能力是静止不变的。决策树和KNN是经典的机器学习模型, 可以从数据中学习数据特征或解决问题的方法。

二、KNN

(1) 曼哈顿距离下分类结果是蓝色, 欧几里得距离下分类结果是红色。因为KNN算法的本质是寻找目标点周围一段区域内, 给定数目的样本点中哪种类别分布更多, 不同的距离划分方式会导致区域的不同, 进而导致分类结果不同。

(2) 观察样本点可知, 只需将 y 方向压缩, x 方向适度延长即可将蓝色样本囊括而排除红色样本。因此可以设计矩阵为:

$$\begin{bmatrix} \frac{1}{a} & 0 \\ 0 & \frac{1}{b} \end{bmatrix}, \quad (1)$$

其中 $a > 1, 0 < b < 1$, 加权欧几里得距离为

$$D = \frac{(x_1 - x_2)^2}{a} + \frac{(y_1 - y_2)^2}{b}. \quad (2)$$

此时决策区域在坐标轴上将是一个被“压扁”的椭圆, 长轴与 x 轴重叠。

三、SVM

(1) SVM的常见表达式为

$$\begin{aligned} \min_{\omega, b} \quad & \frac{1}{2} \|\omega\|^2 \\ \text{s.t.} \quad & \forall i, \quad y_i(\omega^\top x_i + b) - 1 \geq 0 \end{aligned} \quad (3)$$

其正是由下式等价转化而来:

$$\begin{aligned} \max_{w, b} \quad & \frac{2}{\|\omega\|^2} \\ \text{s.t.} \quad & \forall i, \quad y_i(\omega^\top x_i + b) - 1 \geq 0 \end{aligned} \quad (4)$$

样本空间中任意一点到超平面的距离为

$$r = \frac{|\omega^\top x + b|}{\|\omega\|} \quad (5)$$

假设正负样本标签以 ± 1 来表示, 则离超平面最近的几个样本点将使得 $|\omega^\top x + b| = 1$ 成立, 故它们离超平面的距离之和为 $\frac{2}{\|\omega\|^2}$, 即为SVM最大化的目标。故最小化 $\|\omega\|^2$ 能够最大化数据点到决策超平面的最小间隔。

隔。

(2) 只需要保持支持向量，即满足 $y_i(\omega^\top x + b) = 1$ 的样本。

四、SVM公式推导

原始问题为：

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|\omega\|^2, \\ \text{s.t.} \quad & y^{(i)}(\omega^\top x^{(i)} + b) \geq 1 \quad (i = 1, 2, \dots, n) \end{aligned} \quad (6)$$

引入拉格朗日乘子 $\lambda_i \geq 0$ ，构造拉格朗日函数：

$$\mathcal{L}(w, b, \lambda) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \lambda_i [y^{(i)}(w^\top x^{(i)} + b) - 1] \quad (7)$$

对 ω, b 求偏导：

$$\begin{aligned} \nabla_w \mathcal{L} = w - \sum_{i=1}^n \lambda_i y^{(i)} x^{(i)} = 0 & \implies w = \sum_{i=1}^n \lambda_i y^{(i)} x^{(i)} \\ \frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \lambda_i y^{(i)} = 0 & \implies \sum_{i=1}^n \lambda_i y^{(i)} = 0 \end{aligned} \quad (8)$$

代入拉格朗日函数 $\mathcal{L}(w, b, \lambda)$ ，有：

$$\begin{aligned} \frac{1}{2} \|w\|^2 &= \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j y^{(i)} y^{(j)} \langle x^{(i)}, x^{(j)} \rangle \\ \implies \mathcal{L} &= \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j y^{(i)} y^{(j)} \langle x^{(i)}, x^{(j)} \rangle. \end{aligned} \quad (9)$$

原问题是为了最小化 $\|\omega\|^2$ ，对偶问题即为最大化拉格朗日函数，且要满足约束条件，故最终对偶问题为：

$$\begin{aligned} \max_{\lambda} \quad & \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j y^{(i)} y^{(j)} \langle x^{(i)}, x^{(j)} \rangle, \\ \text{s.t.} \quad & \sum_{i=1}^n \lambda_i y^{(i)} = 0, \quad \lambda_i \geq 0. \end{aligned} \quad (10)$$

(2) 当数据线性不可分时，需通过非线性变换 $\phi(x)$ 将数据映射到高维特征空间，使其在高维线性可分。此时，原问题中的内积 $\langle x^{(i)}, x^{(j)} \rangle$ 会变为高维空间的内积 $\langle \phi(x^{(i)}), \phi(x^{(j)}) \rangle$ 。由于 $\phi(x)$ 维度极高甚至无穷，导致无法计算。对偶形式则仅涉及样本之间的内积，因此可以直接引入核函数 $K(x^{(i)}, x^{(j)}) = \langle \phi(x^{(i)}), \phi(x^{(j)}) \rangle$ ，无需显式计算 $\phi(x)$ ，只需通过核函数间接计算高维内积，从而实现了非线性变换。

五、决策树

(1) 决策树构建

1、注意到 $p_{\text{否}} = \frac{5}{14}$ ， $P_{\text{是}} = \frac{9}{14}$ ，故根节点的信息熵是：

$$Ent(D) = -\frac{5}{14} \log_2 \frac{5}{14} - \frac{9}{14} \log_2 \frac{9}{14} = 0.9403. \quad (11)$$


2、计算各个特征的信息增益。以天气为例，共包括晴朗、阴天下雨三种情况，各包括5，4，5个样本。对于晴朗天气，2个样本为“是”，3个样本为“否”，可以按照式（11）的方式来计算信息熵为0.9710；对于“阴天”，全部都是“是”，信息熵为0；对于“下雨”天气，3个样本为“是”，2个样本是“否”，其信息熵为0.9710。因此，天气的信息增益可以计算为：

$$Gain(\text{天气}) = Ent(D) - \sum_{i=1}^3 \frac{|D^v|}{|D|} Ent(D^v) = 0.2467. \quad (12)$$

同理可以计算出其他特征的信息增益为

$$Gain(\text{气温}) = 0.0292, \quad Gain(\text{湿度}) = 0.1519, \quad Gain(\text{风力}) = 0.0499. \quad (13)$$

3、天气具有最高的信息增益，因此选取天气作为第一个分类指标。当天气是阴天时，子类中全部为“打球”，因此直接分为一类。当天气为晴朗或者下雨时，子类中均包含“打球”和“不打球”两种情况。因此，在子类中重复步骤2，继续计算剩余特征的信息增益。注意到在晴朗天气时，湿度为高时全部不打球，正常时全部打球，其信息熵最高，因此直接采用其进行分类。同理，在天气为下雨时，风力对应的信息熵最高，可直接使用这一特征进行分类。综上所述，构建的决策树如下图所示：



(2) 根据决策树，天气晴朗且湿度正常时，应当打球。

六、机器学习算法判断

- (1) 是KNN。决策边界极不规则，受单一样本影响较大。
- (2) 是决策树。决策边界为水平横线和竖直竖线的组合，符合决策树逐次分类的特点。
- (3) 是MLP。决策边界曲折，且受孤立噪声点影响小，符合MLP拟合效果好、泛化性较强的特点。
- (4) 是SVM。决策边界为一道斜线，符合SVM线性分类的特点。

七、逻辑回归

注意到

$$P_i = \frac{1}{1 + e^{-\omega^\top x}}, \quad 1 - P_i = \frac{e^{-\omega^\top x}}{1 + e^{-\omega^\top x}} \quad (14)$$

带入定义式有：


$$\begin{aligned} L(\omega) &= \sum_{i=1}^n \left[y_i \log(1 + e^{-\omega^\top x}) + (1 - y_i) \left(\log(1 + e^{-\omega^\top x}) - \log(e^{-\omega^\top x}) \right) \right] \\ &= \sum_{i=1}^n \left[\log(1 + e^{-\omega^\top x}) - (1 - y_i) \log(e^{-\omega^\top x}) \right] \\ &= \sum_{i=1}^n \left[\underbrace{\log(1 + e^{-\omega^\top x})}_{=L_1(\omega)} + (1 - y_i) \omega^\top x \right] \end{aligned} \quad (15)$$

第二项是线性项，其Hessian矩阵为零矩阵。故只需要计算第一项：

$$\begin{aligned} \frac{\partial L_1(\omega)}{\partial \omega} &= - \sum_{i=1}^n \frac{e^{-\omega^\top x}}{1 + e^{-\omega^\top x}} x = - \sum_{i=1}^n \left(1 - \frac{1}{1 + e^{-\omega^\top x}} \right) x \\ \Rightarrow H(\omega) &= \frac{\partial^2 L_1(\omega)}{\partial \omega^2} = - \sum_{i=1}^n \frac{e^{-\omega^\top x}}{(1 + e^{-\omega^\top x})^2} x x^\top. \end{aligned} \quad (16)$$

八、Lasso回归

在Lasso回归中，当且仅当残差椭圆与范数约束区域的切点在坐标轴上取得时，某些特征系数会被直接压缩到0。因此，只需要将范数约束区域画的足够大，使得切点无法在坐标轴上取得，那么最优解就将不会导致任何特征系数归零。如下图橙色区域所示：



此时残差椭圆与约束区域的切点落在第一象限，所有特征系数都不为0。