

第二次作业

第一题：包装法（Bagging）

（1）考虑如下的小数据集 $D = \{(x_i, y_i)\}_{i=1}^6$ ，请手动使用包装法建立集成模型对**是否打球**进行决策，其中样本 2 是引入的噪声。基分类器 $f_b(x)$ ($b = 1, 2, 3$) 使用最大深度为 2 的决策树，其中令 $D^{(1)} = D$ ， $D^{(2)}$ 、 $D^{(3)}$ 请自行做自助采样（bootstrap）。

（2）对于测试样本 7：（天气晴朗，气温热，湿度高，风力弱），比较单棵决策树与集成模型的预测结果。

（3）简便起见，设单个基学习器 $f_b(x)$ 在不同的 bootstrap 样本上训练后，其预测的方差（variance）为 σ^2 ，不同学习器之间的相关系数为 ρ 。请解释为什么集成后的模型 $f_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B f_b(x)$ 能够减小方差，并指出 $\rho = 1$ 和 $\rho = 0$ 时的含义。

标号	天气	气温	湿度	风力	是否打球
1	晴朗	热	高	弱	否
2	晴朗	热	高	强	是
3	阴天	热	高	弱	是
4	有雨	适中	高	弱	是
5	有雨	冷	正常	强	否
6	晴朗	冷	正常	弱	是

第二题：提升法（Boosting）

（1）给定以下的 1D 训练数据集 ($N = 10$)，我们的弱分类器 $h(x)$ 是决策树桩（Decision stump），它通过一个阈值 θ 和一个方向 $p \in \{+1, -1\}$ 来进行分类： $h(x) = p \cdot \text{sign}(x - \theta)$, $\theta = 0.5, 1.5, 2.5, \dots, 9.5$ 。例如， $h(x) = +1 \cdot \text{sign}(x - 3.5)$ 表示 $x > 3.5$ 时为+1，否则为-1。请手动执行 AdaBoost (Adaptive Boosting) 算法 $T = 3$ 轮，展示每一轮的计算过程并给出最终的强分类器 $H(x)$ 的表达式，计算 $H(x)$ 的训练准确率。


（2）请解释分类器权重 α_i 的变化（变大/变小）。为什么这种加权组合通常不会让模型的整体性能变差？

（3）请解释提升法为何是一种能有效降低模型偏差（Bias）的算法。

样本 i	1	2	3	4	5	6	7	8	9	10
x_i	1	2	3	4	5	6	7	8	9	10
y_i	+1	+1	+1	-1	-1	-1	+1	+1	+1	-1

第三题：聚类

（1）请指出下图中四种数据分布分别适合哪些聚类算法？（候选项：K-means，DBSCAN，Spectral）



（2）对于图（b），描述 K-means 与 DBSCAN 算法的聚类过程，并大致画出两种算法的聚类结果。

第四题：SimCLR

A Simple Framework for Contrastive Learning of Visual Representations. ICML 2020. [URL](#).

- （1）在 SimCLR 模型中，编码器（encoder）后接有一个投影头（projection head），如果在训练中不使用 projection head，会对模型学到的特征表示和下游任务性能产生怎样的影响？
- （2）SimCLR 使用 pairwise contrastive loss 进行优化。请分析当 batch size 增大或减小时，分别会产生什么影响？
- （3）请分析为什么 SimCLR 这样的对比学习算法具有隐式聚类效果？

第五题：在全批量梯度下降（GD）中，对于 μ -强凸且 L -光滑的函数，使用固定步长 η 就可以使算法收敛到精确的最优解 x^* 。然而，在随机梯度下降（SGD）中，情况却有所不同。

（1）相比起全批量 GD，SGD 在计算梯度时引入了噪声，这种噪声使得当 $x \rightarrow x^*$ 时，真实梯度 $\nabla F(x)$ 和随机梯度 $g(x; \xi)$ 的表现有何不同？

（2）下述公式给出了使用固定步长 η 时 SGD 的收敛上界：

$$\mathbb{E}[F(x_t) - F(x^*)] \leq \frac{\eta L \sigma_g^2}{2\mu} + (1 - \eta\mu)^t (F(x_0) - F(x^*)),$$

请解释在实践中，这个收敛上界意味着 SGD 算法的长期行为是怎样的？

（即 x_t 和 x^* 的关系是怎样的）

（3）为了让 SGD 能够精确收敛（即 $\mathbb{E}[F(x_t) - F(x^*)] \rightarrow 0$ ），我们对步长 η_t 的设计有什么定性要求？

第六题：Adagrad 使用 $s_t = s_{t-1} + g_t^2$ 来累积历史平方梯度，并用 $\frac{\eta}{\sqrt{s_t + \epsilon}}$ 作为逐参数的学习率。

（1）考虑一个同时包含稀疏特征（对应的梯度 $g_t(i)$ 在大多数时候均为 0）和稠密特征（对应的梯度 $g_t(j)$ 在大多数时候均非 0）的任务。在这种情况下，Adagrad 如何自动地为这两种特征分配不同大小的学习率？为什么 Adagrad 这个特性使其在处理这类任务时，通常比使用单一全局学习率的 SGD 收敛得更快？

（2）历史平方梯度 s_t 具备累积特性（即只增不减），这使得学习率不断衰减。在具备多个局部最优的非凸优化问题中，这种特性会导致什么问题，并使得 Adagrad 的表现可能不如带有动量的 SGD？

第七题：近端梯度下降（Proximal Gradient Descent）算法用于优化函数 $F(x) = f(x) + h(x)$ ，其中 $f(x)$ 为光滑函数， $h(x)$ 为不可导的正则项（例如 $\|\cdot\|_1$ ）。算法的迭代步骤为：

$$x^{(k)} = \text{prox}_{t_k h} \left(x^{(k-1)} - t_k \nabla f(x^{(k-1)}) \right),$$

这里 $\nabla f(x^{(k-1)})$ 是 f 的真实梯度。

我们知道，标准梯度下降（GD）可以通过用随机梯度 g_k 替换真实梯度 ∇f ，转变为随机梯度下降（SGD）。那么，近端梯度下降是否能和 SGD 的这种思想相结合？若不行，请简述理由；若可以，请写出结合后算法在第 k 步迭代的更新步骤。