

机器学习第三次作业

≡ 姓名 周瑞奇 2025210719 电子工程系

一、MLP

(1) Sigmoid函数: $\sigma(x) = \frac{1}{1+\exp(-x)}$, ReLU函数: $f(x) = \max(0, x)$ 。导数分别为:

$$\sigma'(x) = \frac{\exp(-x)}{(1 + \exp(-x))^2}, \quad f'(x) = \begin{cases} 1, & x > 0 \\ 0, & x < 0 \end{cases} \quad (1)$$

ReLU主要解决了深层网络中的梯度消失问题。Sigmoid函数只有在 $x = 0$ 附近才有较大的梯度值,且仍然小于0.25。这导致在反向传播时梯度会被持续缩小,最终接近于0,从而无法有效训练网络。ReLU在 $x > 0$ 时的导数恒为1,能够有效保留梯度并加速网络训练。

(2) PReLU的表达式为 $f(x) = \max(\alpha x, x)$,其中 $\alpha < 1$ 是可学习的小参数。于ReLU相比, PReLU有效地解决了当输入小于0时,梯度和神经元的值被直接置为0导致神经元“死亡”的问题,增强了网络的表示能力。同时,由于 α 是一个可以学习的小参数,与Leaky ReLU相比, PReLU还能根据数据分布来自适应调整 $x < 0$ 时的梯度,提升了网络的灵活性。

(3) 几乎没有影响。因为 $x = 0$ 是一个零测集,在实际计算时准确取得 $x = 0$ 的概率几乎为0。同时,在 $x = 0$ 时也可以人为指定一个梯度值,如 $\frac{1}{2}$ 或其单侧导数,不会造成训练的不稳定。

(4) ELU激活函数为:

$$\text{ELU}(x) = \begin{cases} \alpha(\exp(x) - 1) & x \leq 0 \\ x, & x > 0 \end{cases} \quad (2)$$

相较于PReLU, ELU连续且光滑,且当 $\alpha = 1$ 时,处处连续可导,因此训练过程更加稳定。然而,由于引入了指数函数的计算,其计算成本更高。此外,ELU中的 α 是一个需要手工调节的超参数,但PReLU的参数则可以被自主学习,因此ELU的灵活性较差。

二、CNN

(1) A是 9×9 卷积, B是 3×3 卷积。因为 9×9 卷积的感受野更大,提取出的图片会更加模糊, 3×3 卷积则会保留更多的细节特征。

(2) A是浅层卷积, B是深层卷积。因为A的图像中仍然保留着大量的像素块,而B中则呈现出明显的抽象特征,图像更加平滑,符合深层卷积特征凝炼度更高的特点。

(3) A是空洞卷积, B是标准卷积。因为空洞卷积的感受野更大,会略去毛发等细粒度特征。B中仍然保留着大量的毛发和背景特征, A则几乎只保留了熊猫的轮廓。

三、GNN

(1) 注意到 $X^{(1)} = PX^{(0)}W_0$, $X^{(2)} = PX^{(1)}W_1 = P^2X^{(0)}W_0W_1$, 归纳可得:

$$X^{(L)} = P^L X^{(0)} W_0 W_1 \cdots W_{L-1} \quad (3)$$

(2) 考虑 P 矩阵的特征值分解 $P = U\Lambda U^\top$ ，其中 $\Lambda = \text{diag}\{\lambda_i\}$ 。故：

$$P^L = U\Lambda^L U^\top. \quad (4)$$

又因为 $\lambda_i \in (-1, 1]$ ，故：

$$\lim_{L \rightarrow \infty} \Lambda^L = \begin{bmatrix} I_r, 0 \\ 0, 0 \end{bmatrix}. \quad (5)$$

其中 r 是 P 矩阵中特征值为 1 的个数。因此， P^L 会损失对应特征值小于 1 的向量的信息，趋近于投影到 P 的 $\lambda = 1$ 对应的特征子空间上的投影矩阵。

(3) 当 L 逐渐变大时， Λ^L 的秩会逐渐变小，而：

$$X^{(L)} \leq \min\{r(P^L), r(X^{(0)}), r(W_0 \cdots W_{L-1})\} \leq \min\{r(U), r(\Lambda^L)\}. \quad (6)$$

故 $X^{(L)}$ 的秩也会逐渐变小。亦即： $X^{(L)}$ 的行向量出现了线性相关的关系，传递的信息减少，不同节点的特征表示出现了同质化现象，最终导致 GNN 无法有效地进行节点分类。

四、Transformer

(1) 正弦位置编码通过不同频率的正弦/余弦函数为序列中的每个位置生成唯一的向量编码：

$$PE(k, 2i) = \sin\left(\frac{k}{10000^{\frac{2i}{d_{model}}}}\right), \quad PE(k, 2i+1) = \cos\left(\frac{k}{10000^{\frac{2i}{d_{model}}}}\right). \quad (7)$$

其中， k 是序列位置， d_{model} 是特征维度。同时，利用三角函数的特殊关系，对于同样的位置间隔， $PE(k + \Delta k)$ 可以表示为 $PE(k)$ 的线性变化，因此能够有效地反映不同 token 的相对位置关系。相对于可学习的位置编码，正弦位置编码主要具有以下几个方面的优势：

- 无需存储额外参数。所有编码都由确定函数生成的，模型更加轻量化。
- 泛化性更强。可学习的位置嵌入只在最大序列长度内有效，超出长度的位置无对应编码。但正弦位置编码支持任意长度的序列。
- 正弦位置编码天然蕴含相对位置信息，但可学习位置嵌入使绝对位置的独立向量，难以建模相对位置。

(2) 对第一个苹果，可能会关注“打开”“电脑”等词，来表示其是一个电脑的品牌。对第二个苹果，会关注“吃”这个词，来表示其是一个可以食用的水果。

(3) 不能。Transformer 的核心是自注意力机制，而自注意力是无序的。它仅计算 token 之间的关联度，不包含任何序列顺序信息。位置编码是 Transformer 注入顺序信息的唯一方式，若去掉，模型无法区分“我吃苹果”和“苹果吃我”这类序列的语义差异，因此无法正确理解序列顺序。

五、Generative Model

(1) 为了近似建模数据分布，需要最大化对数似然函数，即：

$$\log p(x) = \log \int p(x, z) dz. \quad (8)$$

引入后验分布 $q(z)$ ，有：

$$\log p(x) = \log \int q(z|x) \frac{p(x, z)}{q(z|x)} dz = \log \mathbb{E}_{z \sim q} \left[\frac{p(x, z)}{q(z|x)} \right]. \quad (9)$$

依Jensen不等式，

$$\log \mathbb{E}_{z \sim q} \left[\frac{p(x, z)}{q(z|x)} \right] \geq \mathbb{E}_{z \sim q} \left[\log \frac{p(x, z)}{q(z|x)} \right] \quad (10)$$

故VAE的对数似然函数满足：

$$\log p(x) \geq \mathbb{E}_{z \sim q} \left[\log \frac{p(x, z)}{q(z|x)} \right] := \text{ELBO}. \quad (11)$$

因此，最大化ELBO即可最大化对数似然函数，从而达到近似建模数据分布的目的。进一步的，利用 $p(x, z) = p(x|z)p(z)$ ，代入 (11) 中有：

$$\text{ELBO} = \mathbb{E}_{z \sim q} \left[\log \frac{p(x|z)p(z)}{q(z|x)} \right] = \mathbb{E}_{z \sim q} [\log p(x|z)] - \mathbb{E}_{z \sim q} \left[\log \frac{q(z|x)}{p(z)} \right] \quad (12)$$

式中第一项即为重构项，目的是为了衡量解码器从隐变量 z 中重构原始数据 x 的能力；第二项即为KL散度项，目的是为了约束 $q(z|x)$ 接近先验分布 $p(z)$ ，保证隐变量空间的规整性和连续性，避免冗余。

(2) GNN不直接建模数据的概率密度，而是通过生成器和判别器的对抗博弈来匹配数据分布。生成器 G 从噪声分布 z 中采样，生成假样本 $G(z)$ ，判别器 D 则输出样本为真实数据的概率，目标是区分假样本 $G(z)$ 和真实样本 x 。在训练过程中：

- 判别器最大化 $\mathbb{E}_{x \sim p_{\text{data}}} \log D(x) + \mathbb{E}_{z \sim p_z} \log (1 - D(G(z)))$,
- 生成器最大化 $\mathbb{E}_{z \sim p_z} \log (1 - D(G(z)))$ 。

最终收敛时，判别器无法区分出假样本和真实样本，生成器生成的样本分布接近真实样本分布。从而达到学习数据分布的目的。

(3) 选择VAE。

- 训练稳定性：VAE的训练目标是优化变分下界（ELBO），这是一个连续、可稳定优化的目标函数，训练过程稳定；而GAN是生成器与判别器的“对抗训练”，容易出现模式崩溃、训练震荡（比如判别器过强导致生成器无法学习，或生成器只输出少数样本）。
- 样本质量：VAE通过“重建项”约束生成样本与真实样本的结构一致性，生成结果的医学结构（如器官形态、病变区域位置）更稳定；而GAN可能为了骗过判别器而过度优化视觉细节，破坏医学结构的合理性，因此VAE的样本质量更适配医学任务。
- 潜在空间解释性：VAE的潜在空间是结构化、连续且可解释的。KL散度项约束潜在分布接近标准正态分布，可以通过调整潜在变量来控制生成图像的特征。而GAN对于数据的建模过程完全是黑箱的，缺乏医学场景需要的可解释性。